文档的倒排索引与二级索引实现方案

小组成员

组员姓名	学号	教学班
洪子翔	1820211062	07812101
何秉翰	1820211061	07812101
陈晓如	1820211064	07812101
杨珍奇	1820211050	07832101
金泰显	1820191052	07832101

1. 实验要求

运用 MapReduce 算法计算,构建一个倒排索引,将倒排索引存储在 HBase 中。

2. 数据准备

下载数据之后,按照句子数量(例如 10000 个句子)构成一个文件,形成一个拥有940 个文件的集合。此处使用 Python 脚本程序来实现文件分割的工作。

3. 环境的安装与配置

Hadoop 集群搭建

本次实验搭建的环境版本

VMware WorkStation 16 Pro

hadoop-3. 3. 6

hbase-2.5.5

jdk1.8.0_241

zookeeper-3.8.2

CentOS Linux release 7.7.1908 (Core)

Hadoop 集群分布式安装

集群规划

主机	hadoop102	hadoop103	hadoop104
角色	NameNode DataNode NodeManager JobHistoryServer QuorumPeerMain HMaster HRegionServer	DataNode ResourceManager NodeManager QuorumPeerMain HRegionServer	SecondaryNameNode DataNode NodeManager QuorumPeerMain HRegionServer

集群节点设置

- 1. 修改主机名
- 2. host 映射
- 3. 关闭防火墙
- 4. 开启 ssh 免密登录

Hadoop 安装

- 1. 下载并解压 Hadoop 安装包: tar -zxvf hadoop-3.3.6.tar.gz -C /opt/module/
- 2. 修改以下配置文件: hadoop-env. sh、core-site. xml、hdfs-site. xml、mapred-site. xml、yarn-site. xml、workers。因为配置文件很多,要修改的内容也很多,故不再把这些配置文件的所有内容在此列出
- 3. 添加 hadoop 到环境变量

4. 首次启动之前格式化 namenode

HBase 安装

ZooKeeper 搭建

- 1. 下载并解压 Zookeeper 安装包: tar -zxvf apache-zookeeper-3.8.2-bin.tar.gz -C /opt/module/
- 2. 进入 zookeeper 的安装目录下创建 zkDdata 目录,存放我们的数据: mkdir zkData
- 3. 进入 conf 目录, 把 zoo_sample. cfg 改名为 zoo. cfg:

```
cd conf/ //进入 conf 目录
cp zoo_sample.cfg zoo.cfg //复制一份,名为 zoo.cfg
```

- 4. 修改 zoo.cfg 文件: vim zoo.cfg
- 5. 进入 zoo. cfg 文件添加和修改 dataDir 和 server node:

dataDir=/opt/module/zookeeper-3.8.2/zkData //更改 Data 的 Directory

```
server. 2=hadoop102:2888:3888 //更改 ServerNode server. 3=hadoop103:2888:3888 //更改 ServerNode server. 4=hadoop104:2888:3888 //更改 ServerNode
```

6. 配置 myid, 设置当前服务器的编号:

```
cd /opt/module/zookeeper-3.8.2/zkData/
echo 2 > myid
```

7. 使用集群分发脚本 xsync,将 zookeeper 文件夹分发到集群上的其他节点

```
//集群分发到 hadoop102, hadoop103, hadoop104
```

xsync /opt/module/zookeeper-3.8.2

Hbase 搭建

1. 下载并解压 hbase: tar- zxvf hbase-2.5.5-bin.tar.gz -C /opt/module/ 2. 配置: cd /opt/module/hbase-2.5.5/conf 3. 修改 hbase-env. sh: cp hbase-env. sh hbase-env. sh. bak 告诉 hbase 使用外部的 zookeeper: export JAVA HOME=/opt/module/jdk1.8.0 241, export HBASE_MANAGES_ZK=false 5. 备份并修改 conf 下 hbase-site. xml 为如下内容: property> <name>hbase.cluster.distributed <value>true</value> property> <name>hbase.zookeeper.quorum <value>hadoop102, hadoop103, hadoop104</value> </property> property> <name>hbase.zookeeper.property.dataDir <value>/opt/module/zookeeper-3.8.2/zkData</value> </property> property>

```
<name>hbase.rootdir</name>
   <value>hdfs://hadoop102:8020/hbase</value>
 </property>
 property>
   <name>hbase.wal.provider
   <value>filesystem</value>
 property>
   <name>hbase.server.keyvalue.maxsize
   <value>57671680</value>
 property>
   <name>hbase.client.keyvalue.maxsize
   <value>57671680</value>
 6. 配置 conf 路径下 regionservers,添加内容:
  hadoop102
            #配置 conf 路径下 regionservers,添加内容
  hadoop103 #配置 conf 路径下 regionservers,添加内容
  hadoop104 #配置 conf 路径下 regionservers,添加内容
7. 将使用集群分发脚本 xsync,将 hbase 文件夹分发到集群上的其他节点
  //集群分发到 hadoop102, hadoop103, hadoop104
  xsync /opt/module/hbase-2.5.5
```

Shell 脚本程序

在开发的过程中,为了轻松自动化地执行各种常规任务,提高工作效率,我们团队一 共编写了 4 个方便且快捷的 Shell 脚本程序,它们分别是:

1. 集群分发脚本: xsync

作用:循环复制文件到所有节点的相同目录下

```
#!/bin/bash
#1. 判断参数个数
if [ $# -lt 1 ]
then
    echo Not Enough Arguement!
    exit:
fi
#2. 遍历集群所有机器
for host in hadoop102 hadoop103 hadoop104
do
    echo ============= $host ===========
    #3. 遍历所有目录,挨个发送
    for file in $@
    do
        #4. 判断文件是否存在
        if [ -e $file ]
            then
                #5. 获取父目录
                pdir=$(cd -P $(dirname $file); pwd)
                #6. 获取当前文件的名称
                fname=$(basename $file)
                ssh $host "mkdir -p $pdir"
                rsync -av $pdir/$fname $host:$pdir
            else
                echo $file does not exists!
        fi
    done
done
```

2. Hadoop 集群启停脚本(包含 HDFS、YARN、HistoryServer): myhadoop.sh

3. Zookeeper 集群启动停止脚本: zk. sh

```
#!/bin/bash
case $1 in
"start") {
    for i in hadoop102 hadoop103 hadoop104
         echo -----zookeeper $i 启动 --
         ssh $i "/opt/module/zookeeper-3.8.2/bin/zkServer.sh start"
'stop") {
    for i in hadoop102 hadoop103 hadoop104
         echo -----zookeeper $i 停止 --
         ssh $i "/opt/module/zookeeper-3.8.2/bin/zkServer.sh stop"
    done
"status") {
    for i in hadoop102 hadoop103 hadoop104
         echo ------ zookeeper $i 状态 ---
         ssh $i "/opt/module/zookeeper-3.8.2/bin/zkServer.sh status"
    done
```

4. 查看三台服务器 Java 进程脚本: jpsall

4. 算法与实现

文件分割

```
fileInput = "D:\\bigData\\sentences\\sentences.txt"
root = "D:\\PythonProject\\splitSentencesFile\\sentencesMFile"
SPLIT NUM = 10000
f = open(fileInput)
lines = f.readlines()
fileId = 1
outputFileName = str(fileId).zfil1(3) + ".txt"
outputFilePath = root + "\\" + outputFileName
output = open(outputFilePath, 'a')
sentencesNum = 1
row = 1
for line in lines:
    output. write(line)
    if row % SPLIT_NUM == 0 and sentencesNum != len(lines):
        print(f"file_{fileId} has {row} rows, Done!")
        output. close()
        fileId += 1
        outputFileName = str(fileId).zfill(3) + ".txt"
        outputFilePath = root + "\\" + outputFileName
```

```
output = open(outputFilePath, 'a')

sentencesNum += 1
  row = 1

continue

sentencesNum += 1
  row += 1

sentencesNum -= 1

row -= 1

print(f"file_{fileId} has {row} rows, Done!\n")

print(f"sentencesNum = {sentencesNum}, splitNum = {SPLIT_NUM}")

print(f"fileNum = {fileId}\n")

output.close()

f.close()
```

倒排索引

以下是代码实现的部分

InvertedIndexMapper. java

```
package com. bingh. mapreduce. invertedindex;

import org. apache. hadoop. io. LongWritable;

import org. apache. hadoop. io. Text;

import org. apache. hadoop. mapreduce. Mapper;

import java. io. IOException;
```

```
public class InvertedIndexMapper extends
Mapper < Long Writable, Text, Text, Long Writable > {
  private Text outKey = new Text();
  private LongWritable outValue = new LongWritable();
  @Override
  protected void map (LongWritable key, Text value,
Mapper Long Writable, Text, Text, Long Writable. Context
context) throws IOException, InterruptedException {
      // 1. 获取一行内容
      String line = value.toString();
      // 2. 分割行内容为两个部分
      String[] linePart = line.split(" ", 2);
      // 3. 转换句子编号的类型, String -> long
      long sentenceId = Long. parseLong(linePart[0]);
      // 4. 以空格作为分隔符,切割句子内容中的各个单词,把
切割结果存储到 words 中
      String[] words = linePart[1].split(" ");
      // 5. 遍历各个单词, 封装, 写出
      for (String word : words) {
         // 5.1 封装
```

```
outKey.set(word);
outValue.set(sentenceId);

// 5.2 写出
context.write(outKey, outValue);

}
```

InvertedIndexReducer. java

```
package com. bingh. mapreduce. invertedindex;
import org. apache. hadoop. hbase. client. Mutation;
import org. apache. hadoop. hbase. client. Put;
import org. apache. hadoop. hbase. mapreduce. TableReducer;
import org. apache. hadoop. hbase. util. Bytes;
import org. apache. hadoop. io. LongWritable;
import org. apache. hadoop. io. NullWritable;
import org. apache. hadoop. io. Text;
import org. apache. hadoop. mapreduce. Reducer;
import java. io. IOException;
import java. util. HashSet;

public class InvertedIndexReducer extends TableReducer<Text,
LongWritable, NullWritable outKey = NullWritable.get();</pre>
```

```
private Put outValue;
  @Override
  protected void reduce (Text key, Iterable < Long Writable >
values, Reducer<Text, LongWritable, NullWritable,
Mutation>. Context context) throws IOException,
InterruptedException {
      // 1. 创建一个 HashSet 对象: HashSetId, 用于存储该单词
出现的所有句子编号
      // 集合中的句子编号都是唯一不重复的(在同一个句子中可
能出现多次该单词)
      HashSet < Long > HashSetId = new HashSet <> ();
      // 2. 出现该单词的句子编号不重复地添加进集合
      for (LongWritable value : values) {
             HashSetId. add(value. get());
      // 3. 创建一个StringBuilder对象: StringId,用于拼接
集合元素的内容
      StringBuilder StringId = new StringBuilder();
      // 3.1 插入 '(' 到 String Id
      StringId. append ("(");
      // 3.2 遍历集合中的句子编号, 追加到 String Id
      for (Long sentenceId : HashSetId) {
         StringId. append (sentenceId). append (", ");
```

```
// 3.3 以 ')' 替代最后一个逗号
      if (StringId.length() > 0) {
          StringId. setCharAt(StringId. length() - 1, ')');
      // 4. 设置单词为 rowKey, 创建 Put 对象
      outValue = new Put(Bytes.toBytes(key.toString()));
      // 5. 指定插入的列族、列名和值
      outValue.addColumn(Bytes.toBytes("info"),
Bytes. toBytes ("sentenceFrequency"),
Bytes. toBytes(String. valueOf(HashSetId. size())));
      outValue.addColumn(Bytes.toBytes("info"),
Bytes. toBytes ("sentenceId"),
Bytes. toBytes(StringId. toString()));
      // 6. 写出
输出 key 并不重要,重要的是 value, value 的数据会被写入 HBase
      context.write(outKey, outValue);
```

InvertedIndexDriver. java

```
package com. bingh. mapreduce. invertedindex;
import org. apache. hadoop. conf. Configuration;
import org. apache. hadoop. fs. Path;
```

```
import org. apache. hadoop. hbase. HBaseConfiguration;
import org. apache. hadoop. hbase. mapreduce. TableMapReduceUtil;
import org. apache. hadoop. io. LongWritable;
import org. apache. hadoop. io. Text;
import org. apache. hadoop. mapreduce. Job;
import
org.apache.hadoop.mapreduce.lib.input.CombineTextInputFormat
import
org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.util.GenericOptionsParser;
import java.io.IOException;
public class InvertedIndexDriver {
   public static void main(String[] args) throws
IOException, InterruptedException, ClassNotFoundException {
      // 1. 创建 HBase 配置 conf
       Configuration conf = HBaseConfiguration.create();
       // 2. 设置调大客户端和服务端参数为 55MB, 避免当实际插
入的 keyValue 的大小超过默认大小 10MB 限制阈值时,发生报错
       conf. set ("hbase. client. keyvalue. maxsize",
"57671680");
       conf. set ("hbase. server. keyvalue. maxsize",
'57671680");
```

```
String[] otherArgs = new GenericOptionsParser(conf,
args).getRemainingArgs();
      // 4. 获取 job
      Job job = Job.getInstance(conf);
      // 5. 设置 jar 包路径
      job. setJarByClass(InvertedIndexDriver. class);
      // 6. 关联 mapper 和 reducer
      job. setMapperClass(InvertedIndexMapper. class);
      job. setReducerClass(InvertedIndexReducer. class);
      // 7. 设置 map 输出的 kv 类型
      job. setMapOutputKeyClass(Text. class);
      job.setMapOutputValueClass(LongWritable.class);
      // 8. 设置读取输入文件的格式
      // 如果不设置 InputFormat, 默认使用的是
TextInputFormat.class
job. setInputFormatClass(CombineTextInputFormat. class);
      // 9. 虚拟存储切片最大值设置为 12MB
      CombineTextInputFormat.setMaxInputSplitSize(job,
12582912);
      // 10. 根据首字符分区存储
      job. setPartitionerClass (Partition. class);
      job. setNumReduceTasks(36);
```

```
// 11. 设置结果输出到 HBase 表
      // "bingh:bigdata"是已经在 HBase 中建好的表
TableMapReduceUtil.initTableReducerJob("bingh:inverted",
InvertedIndexReducer.class, job, Partition.class);
      // 12. 设置输入路径
      // 这是上传到 HDFS 上多个小文件的父目录
      FileInputFormat.addInputPath(job, new
Path(otherArgs[0]));
      // 13. 提交 job
      boolean result = job.waitForCompletion(true);
      System. exit(result ? 0 : 1);
```

分区类

Partition. java

```
package com.bingh.mapreduce.invertedindex;
import org.apache.hadoop.io.LongWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Partitioner;
import java.util.HashMap;
public class Partition extends Partitioner<Text,
LongWritable> {
```

```
HashMap<String, Integer> partition = new HashMap<>();
   public Partition() {
       setPartition();
   public void setPartition() {
       for (int i = 0; i < 10; i++) {
           String key = String. valueOf(i);
           partition.put(key, i);
       for (int i = 0; i < 26; i++) {
           char letter = (char) ('a' + i);
           String key = String. valueOf(letter);
           partition.put(key, i + 10);
   @Override
   public int getPartition(Text text, LongWritable
longWritable, int NumPartition) {
       String singleWord = text.toString();
       String preWord = singleWord. substring(0, 1);
       return partition.get(preWord);
```

```
}
```

Mapper 阶段

-主要任务是将输入数据拆分成单词,并将每个单词与对应的句子编号(文件 id)进行关联。 这个过程包括了获取输入行、分割行内容、将句子编号转换为长整型、切分句子内容中的单词 ,并最终遍历单词,封装成键值对并输出。

Reducer 阶段

-核心任务是汇总相同单词的句子编号(文件 ID),并将它们有效地存储在 HBase 表中。这个过程包括了创建 HashSet 以确保句子编号的唯一性、遍历输入的句子编号、构建包含句子编号的字符串、将单词作为 rowKey 并创建 Put 对象、指定列族、列名和值,并最终将结果写入HBase 表中。值得强调的是,我们的亮点在于使用哈希表来实现句子编号的去重,并在最初的算法中记录单词在各个句子编号中的频率、具体位置以及单词的整体出现频率,这些信息都被显现在最终的代码中。此外,我们还对生成的倒排文件进行了一些优化修改,以减小文件大小,从而提高检索速度。

Driver 阶段

-它是整个 MapReduce 作业的主控制中心,负责配置和运行作业。这个过程包括创建 HBase 配置、设置参数、解析命令行参数、创建 Job 实例、关联 Mapper 和 Reducer、设置输入格式、配置虚拟存储切片、设置分区器、初始化 TableReducerJob、指定输入路径以及最终提交作业

Partition 分区器

-这是一个自定义组件,用于根据单词的首字母将数据进行分区存储,以确保相同首字母的单词被分配到相同的 Reduce 任务中。这个过程包括初始化分区映射以及实现 getPartition 方法来确定分区编号。值得特别提到的是,这个功能是在满足实验要求的基础上实现的,通过首字母分区存储文件,大大提高了检索的效率。

二级索引

以下是代码实现的部分

WordOffsetMapper. java

```
package WordOffset;
import org. apache. hadoop. io.*;
import org. apache. hadoop. mapreduce.*;
```

```
import java. io. IOException;
public class WordOffsetMapper extends Mapper<LongWritable, Text, Text, LongWritable> {
  private Text word = new Text();
  private LongWritable offset = new LongWritable();
  @Override
  protected void map (LongWritable key, Text value, Context context) throws IOException,
InterruptedException {
      //将输入的 Text 值转换为字符串
      String line = value.toString();
      String[] parts = line.split("\t");
      if (parts.length == 2) {
          String wordText = parts[0];
          String info = parts[1];
          //将单词文本设置到 Text 对象
          word. set (wordText);
          //将偏移量设置到LongWritable对象
          offset.set(Long. parseLong(key. toString()));
          context.write(word, offset);
```

WordOffsetReducer. java

```
package WordOffset;
import org. apache. hadoop. io. *;
import org. apache. hadoop. mapreduce. *;
```

```
import java.io.IOException;

public class WordOffsetReducer extends Reducer<Text, LongWritable, Text, Text> {

    //创建 Text 对象用于存储结果
    private Text result = new Text();

    @Override
    protected void reduce(Text key, Iterable<LongWritable> values, Context context) throws

IOException, InterruptedException {

        StringBuilder offsets = new StringBuilder();

        for (LongWritable offset : values) {
            offsets.append(offset.toString());
        }

        result.set(offsets.toString());

        context.write(key, result);

}
```

WordOffsetDriver.java

```
package WordOffset;
import org. apache. hadoop. conf. Configuration;
import org. apache. hadoop. fs. Path;
import org. apache. hadoop. io. *;
import org. apache. hadoop. mapreduce. *;
import org. apache. hadoop. mapreduce. lib. input. FileInputFormat;
import org. apache. hadoop. mapreduce. lib. output. FileOutputFormat;

public class WordOffsetDriver {
    public static void main(String[] args) throws Exception {
        // 创建 Hadoop 配置对象
        Configuration conf = new Configuration();

        // 创建一个新的作业
        Job job = Job. getInstance(conf, "Word Offset Job");

        // 设置主类
        job. setJarByClass(WordOffsetDriver. class);
```

```
// 设置 Mapper 和 Reducer 类
      job. setMapperClass(WordOffsetMapper. class);
      job. setReducerClass(WordOffsetReducer. class);
      // 设置 Mapper 的输出键值类型
      job. setMapOutputKeyClass(Text. class);
      job. setMapOutputValueClass(LongWritable. class);
      // 设置 Reducer 的输出键值类型
      job. setOutputKeyClass(Text. class);
      job. setOutputValueClass(Text. class);
      // 设置输入和输出路径
      FileInputFormat. addInputPath(job, new Path("D:\\bigData\\output_sentence\\part-r-
00000"));
      FileOutputFormat. setOutputPath(job, new Path("D:\\bigData\\output_Sentences"));
      // 提交作业并等待完成
      boolean success = job.waitForCompletion(true);
      // 根据作业是否成功完成返回适当的退出码
      System. exit(success ? 0 : 1);
```

Mapper 阶段

将倒排索引的每一行文本中的单词和该单词在倒排索引文本中的偏移量按"\t"制表符分割后,提取单词作为键(word),偏移量作为值(offset),封装成一组键值对输出。

Reducer 阶段

根据 Mapper 阶段输出的键值对,合并具有相同单词(key)的所有偏移量值(offsets),将它们拼接成一个字符串(result),即对于每个相同的键,将它们的值合并起来后封装成一组键值对输出。

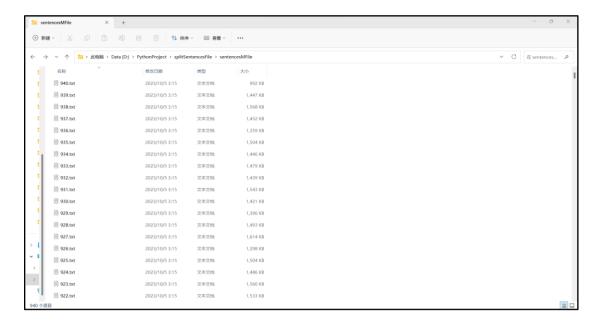
Driver 阶段

是 MapReduce 作业必要的驱动程序,配置了 Hadoop 运行的参数和属性(Configuration)、新作业(Word Offset Job)、主类(WordOffsetDriver)、Mapper 类(WordOffsetMapper)、Reducer 类(WordOffsetReducer)、输出键值类型、输入输出路径和提交作业。

5. 运行结果

→ 倒排索引

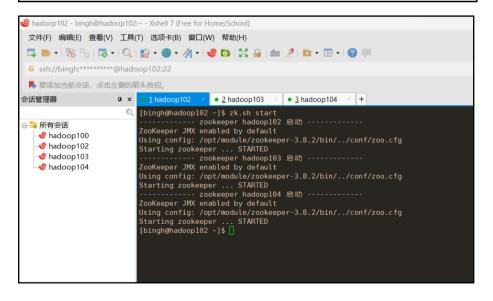
A. 以 10000 个句子为一个小文件单位,利用 Python 脚本对源文件 sentences. txt 内容切割成 940 个小文件



B. 启动集群

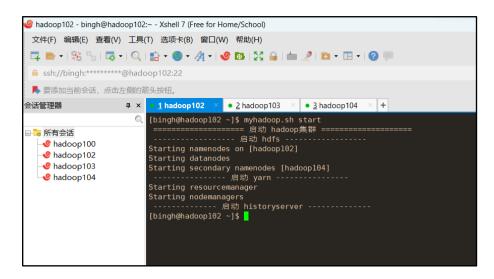
a. 启动 Zookeeper【执行自己编写的 shell 脚本: zk. sh】;

zk.sh start



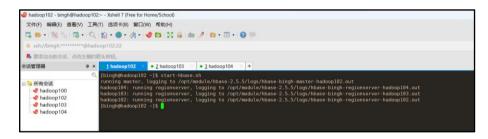
b. 启动 Hadoop【执行自己编写的 shell 脚本: myhadoop.sh】;

myhadoop.sh start



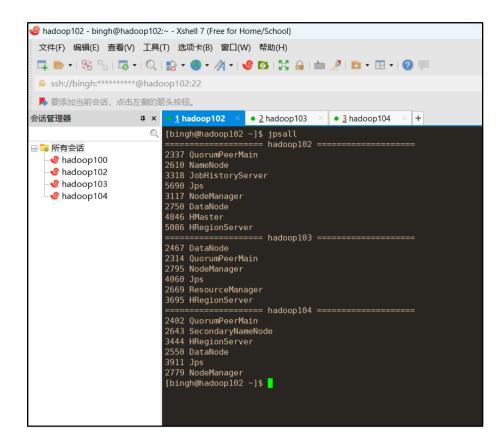
c. 启动 HBase;

start-hbase.sh

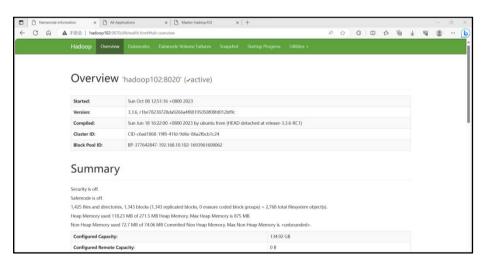


d. 查看当前所有进程状态【执行自己编写的 shell 脚本: jpsall】.

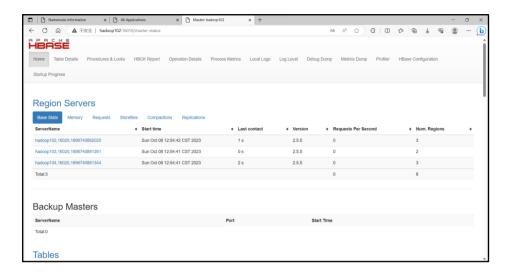
jpsall



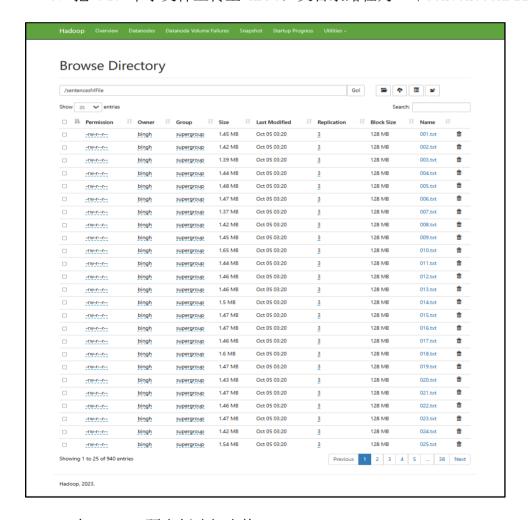
e. 打开 HDFS 网页界面、YARN 管理界面、HBase 网页界面。





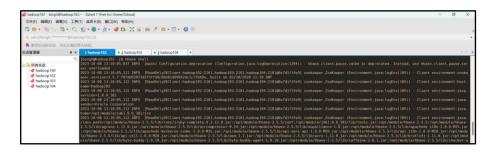


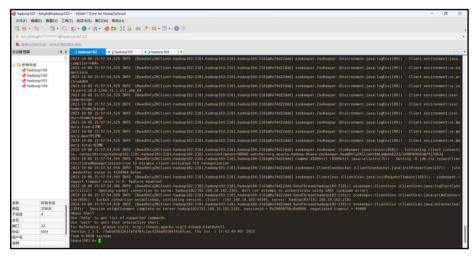
C. 把 940 个小文件上传至 HDFS, 父目录路径为 "/sentencesMFile"



- D. 在 Hbase 预先创建好表格
 - a. 在 HBase 的 HMaster 主机上(即 hadoop102)通过命令行输入 "hbase shell",即可进入 HBase 命令行环境;

hbase shell





b. 新建一个命名空间 'bingh';

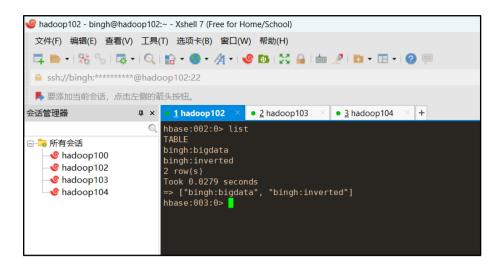
create_namespace 'bingh'

c. 新建一个以命名空间 'bingh' 的表 'bigdata', 列族为 'info';

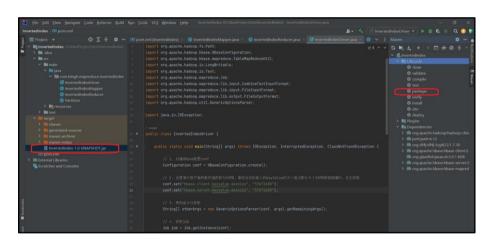
create 'bingh:bigdata', 'info'

d. 列出所有表;

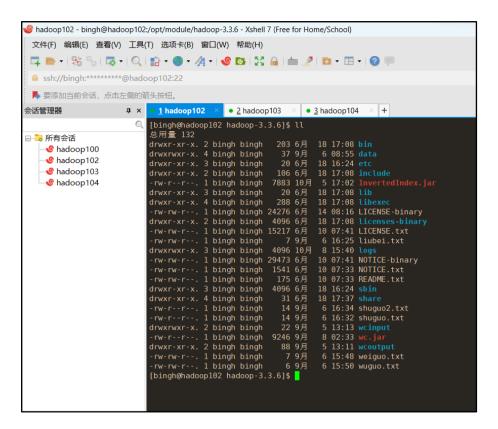
list



- e. 退出 HBase 命令行环境。
- E. 在集群运行倒排索引代码
 - a. 把本地 java 文件打包 (Package) 成 jar 包

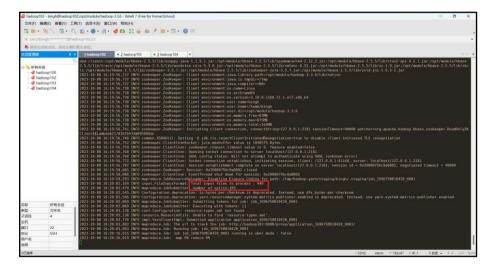


- b. 更改 jar 包名称为 "InvertedIndex. jar"
- c. 复制 jar 包放到 Linux 集群上



d. 使用 "hadoop jar" 命令在 Hadoop 集群中运行 'InvertedIndex. jar" 程序

hadoop jar InvertedIndex.jar com.bingh.mapreduce.invertedindex.InvertedIndexDriver/sentencesMFile

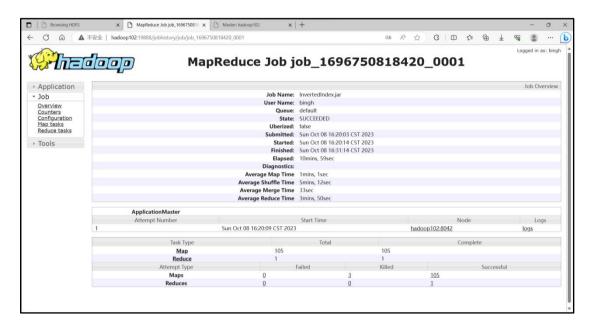


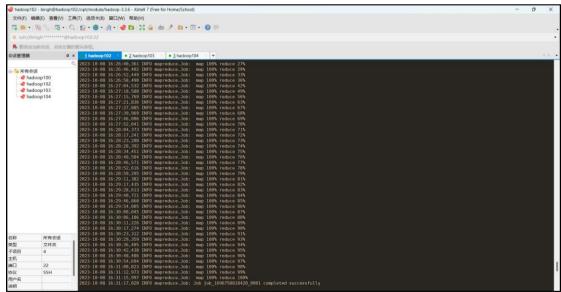
[Total input files to process: 940, number of splits: 105]

F. 查看运行进度



G. 查看运行结果





a. 进入 HBase 命令行环境

hbase shell

b. 统计"bingh:bigdata"表的行数

count "bingh:bigdata"

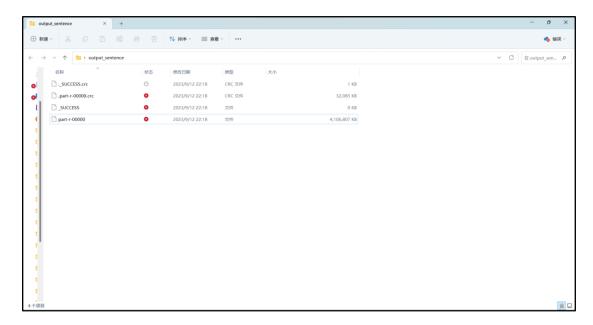
c. 批量查询

scan 'bingh:bigdata', {LIMIT => 10, STARTROW =>
'apple11'}

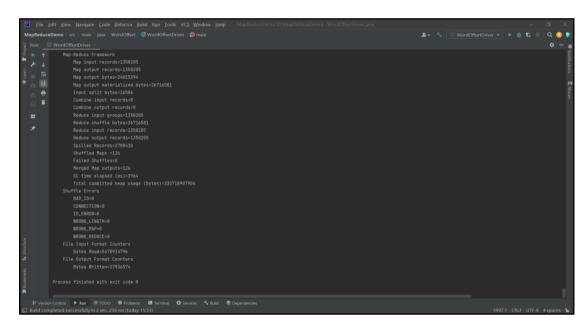
```
| Participation | 100 | Exemplification | 100 | Ask-tile | 2000 |
```

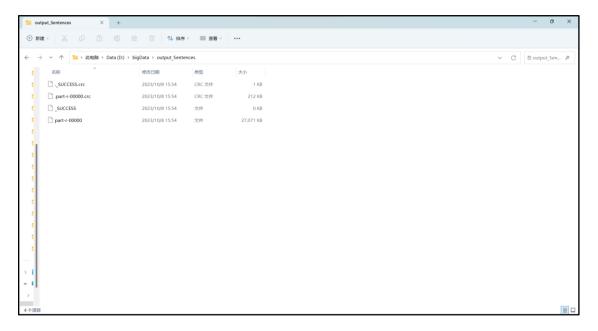
→ 二级索引

A. 运行在本地的倒排索引结果



B. 对倒排索引结果 "part-r-00000" 在本地上运行二级索引代码





C. 查看运行结果



6. 总结

在这个项目中,我们深入了解了 Hadoop 的核心架构,包括资源管理系统、分布式计算框架和分布式文件系统之间的运作关系。我们重点学习了 MapReduce 分布式计算框架的原理,并将其成功运用到离线搜索引擎的实现中。对于许多团队成员来说,这是第一次亲自使用 Hadoop 来管理数据库,我们充分体验了数据处理和分析的高效性,学到了处理大规模数据的能力,以及通过并行处理提高速度和性能的方法。此外,我们认识到 Hadoop 的可扩展性和灵活性,使其成为可应用于各种业务问题的强大工具。这个课程的实验对我们来说是一次巨大的挑战,需要全面理解知识并协调各个模块,以确保小组的进展顺利。这次实验给我们带来了宝贵的经验,也让我们认识到了自己的不

足之处,我们将努力在未来的机会中表现更出色。在搭建实验环境的过程中,我们面临了许多挑战,特别是在 HBase 和 Zookeeper 的配置方面,这部分工作耗费了大量的时间和精力。然而,最终我们成功克服了这些问题,这让我们感到非常满足。我们的团队在这次实验中按照要求一步步解决了问题,最终成功完成了任务。除了满足原始实验要求外,我们还加入了分区和二级索引的功能,以提高搜索效率。我们要感谢所有团队成员,他们积极投入了课后时间,共同完成了这个项目。